ถ้าเกิด Attributes ไม่ได้เป็นตัวเลข Attributes เป็น Binary 1

Proximity Measure for Binary Attributes

- A contingency table for binary data

		Object j		
		1	0	sum
Object i	1	q	r	$q+r$
	0	s	t	$s+t$
	sum	$q+s$	$r+t$	p

ค่าความจริงทั้ง 2 ค่า มีความน่าเป็นเท่ากัน

- Distance measure for symmetric binary variables $d(i, j) = \frac{r+s}{q+r+s+t}$

ค่าความจริงทั้ง 2 ค่า มีความน่าเป็นไม่เท่ากัน

- Distance measure for asymmetric binary variables: $d(i, j) = \frac{r+s}{q+r+s}$

- Jaccard coefficient (*similarity* measure for *asymmetric* binary variables): $sim_{Jaccard}(i, j) = \frac{q}{q+r+s}$

- Note: Jaccard coefficient is the same as (a concept discussed in Pattern Discovery)

$$coherence(i, j) = \frac{sup(i, j)}{sup(i) + sup(j) - sup(i, j)} = \frac{q}{(q+r)+(q+s)-q}$$

Example: Dissimilarity between Asymmetric Binary Variables

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	Male	Y yes/No	Negative	P	N	N	N
Mary	Female	Y	N	P	N	P	N
Jim	M	Y	Positive	N	N	N	N

เพศ จะเป็น symmetric

- Gender is a symmetric attribute (not counted in)
- The remaining attributes are asymmetric binary
- Let the values Y and P be 1, and the value N be 0
- Distance: $d(i, j) = \dfrac{r+s}{q+r+s}$

$$d(jack, mary) = \frac{0+1}{2+0+1} = 0.33 \quad \frac{1}{3}$$

$$d(jack, jim) = \frac{1+1}{1+1+1} = 0.67 \quad \frac{2}{3}$$

$$d(jim, mary) = \frac{1+2}{1+1+2} = 0.75 \quad \frac{3}{4}$$

Jack (rows) × Mary (columns)

	1	0	Σ_{row}
1	2	0	2
0	1	3	4
Σ_{col}	3	3	6

Jack (rows) × Jim (columns)

	1	0	Σ_{row}
1	1	1	2
0	1	3	4
Σ_{col}	2	4	6

Jim (rows) × Mary (columns)

	1	0	Σ_{row}
1	1	1	2
0	2	2	4
Σ_{col}	3	3	6

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M 1	Y 1	N 0	P 1	N 0	N 0	N 0
Mary	F 0	Y 1	N 0	P 1	N 0	P 1	N 0
Jim	M	Y	P	N	N	N	N

Object j

Object i	1	0	sum
1	q	r	$q+r$
0	s	t	$s+t$
sum	$q+s$	$r+t$	p

Mary

Jack	1	0	sum
1	2 q	1 r	3
0	1 s	3 t	4
sum	3	4	7

Symmetric binary

$$d(i, j) = \frac{r+s}{q+r+s+t}$$

$$= \frac{1+1}{2+1+1+3}$$

$$= \frac{2}{7}$$

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M 1	Y 1	N 0	P 1	N 0	N 0	N 0
Mary	F	Y	N	P	N	P	N
Jim	M 1	Y 1	P 1	N 0	N 0	N 0	N 0

Jim

Jack	1	0	sum
1	q	r	
0	s	t	
sum			

Object j

Object i	1	0	sum
1	q	r	$q+r$
0	s	t	$s+t$
sum	$q+s$	$r+t$	p

$$d(i, j) = \frac{r+s}{q+r+s+t}$$

Symmetric binary ต่างกัน 2 $= \frac{2}{7}$

เป็นชื่ออย่างเดียว

Proximity Measure for Categorical Attributes

- Categorical data, also called nominal attributes
  - Example: Color (red, yellow, blue, green), profession, etc.
- Method 1: Simple matching
  - m: # of matches, p: total # of variables

p = Attributes ทั้งหมด

m = จำนวนตัวที่มันเหมือนกัน

$$d(i,j) = \frac{p - m}{p}$$

จน. ตัวที่ไม่เหมือน

จน. ทั้งหมด

- Method 2: Use a large number of binary attributes

Dummy

  - Creating a new binary attribute for each of the M nominal states

Method 2

แปลงจาก Categori เป็น binary

สี	อาชีพ
r	นศษ.
r	อจ.
g	นศษ.

r, g, b

ว่างงาน, นศษ, อาจารย์, Grab

	สี R	สี G	สี B	ว่างงาน	นศษ	อจ.	Grab
1	1	0	0	0	1	0	0
2	1	0	0	0	0	1	0
3	0	1	0	0	1	0	0

ระยะห่างระหว่าง 1 กับ 3 ห่างกันเท่าไหร่ (Binary)

Ans. $\frac{2}{7}$

Ordinal Variables

- An ordinal variable can be discrete or continuous
- Order is important, e.g., rank (e.g., เรียงลำดับได้ freshman, sophomore, junior, senior)
  $\{1, 2, 3, 4\}$
- Can be treated like interval-scaled
  - Replace *an ordinal variable value* by its rank: $r_{if} \in \{1, \ldots, M_f\}$
  - Map the range of each variable onto [0, 1] by replacing *i*-th object in the *f*-th variable by

    ลำดับที่เท่าไหร่

    $$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

    ใครระยะห่าง

    $\frac{1-1}{4-1} = \frac{0}{3} = 0$ $\qquad$ $\frac{2-1}{4-1} = \frac{1}{3}$

    - Example: freshman: 0; sophomore: 1/3; junior: 2/3; senior 1
      - Then distance: d(freshman, senior) = 1, d(junior, senior) = 1/3
  - Compute the dissimilarity using methods for interval-scaled variables

Attributes of Mixed Type

- A dataset may contain all attribute types
  - Nominal, symmetric binary, asymmetric binary, numeric, and ordinal
- One may use a weighted formula to combine their effects:

$$d(i,j) = \frac{\sum_{f=1}^{p} w_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^{p} w_{ij}^{(f)}} \rightarrow y\left(\frac{4}{6}\right) + x\left(\frac{2}{6}\right)$$

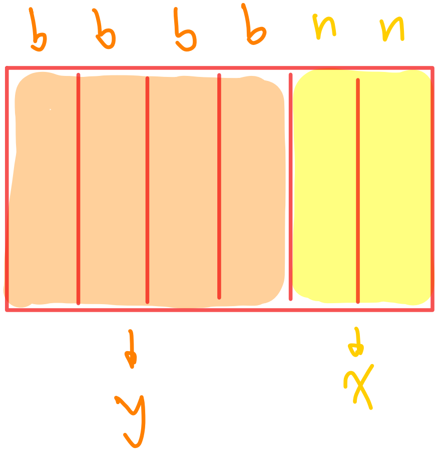

  - If f is numeric: Use the normalized distance
  - If f is binary or nominal: $d_{ij}^{(f)} = 0$ if $x_{if} = x_{jf}$; or $d_{ij}^{(f)} = 1$ otherwise
  - If f is ordinal
    - Compute ranks z_{if} (where $z_{if} = \frac{r_{if} - 1}{M_f - 1}$)
    - Treat z_{if} as interval-scaled

Cosine Similarity of Two Vectors

- A **document** can be represented by a bag of terms or a long vector, with each attribute recording the *frequency* of a particular term (such as word, keyword, or phrase) in the document

Document	*team*	*coach*	*hockey*	*baseball*	*soccer*	*penalty*	*score*	*win*	*loss*	*season*
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

- Other vector objects: Gene features in micro-arrays
- Applications: Information retrieval, biologic taxonomy, gene feature mapping, etc.
- Cosine measure: If d_1 and d_2 are two vectors (e.g., term-frequency vectors), then

$$cos(d_1, d_2) = \frac{d_1 \bullet d_2}{\| d_1 \| \times \| d_2 \|}$$

where • indicates vector dot product, $||d||$: the length of vector d

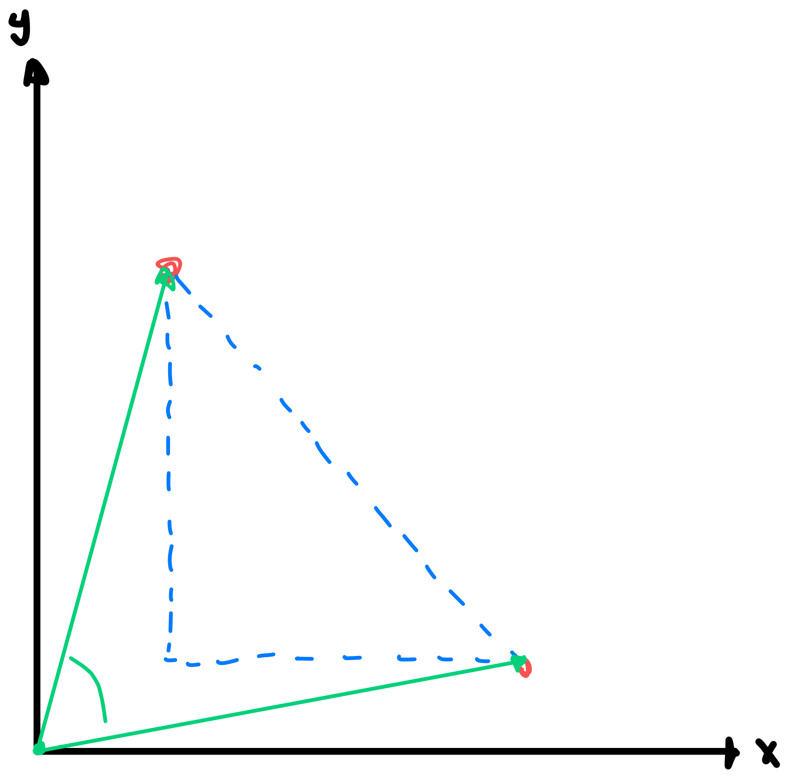

มอง data เป็นเวกเตอร์ แล้ววัดมุม

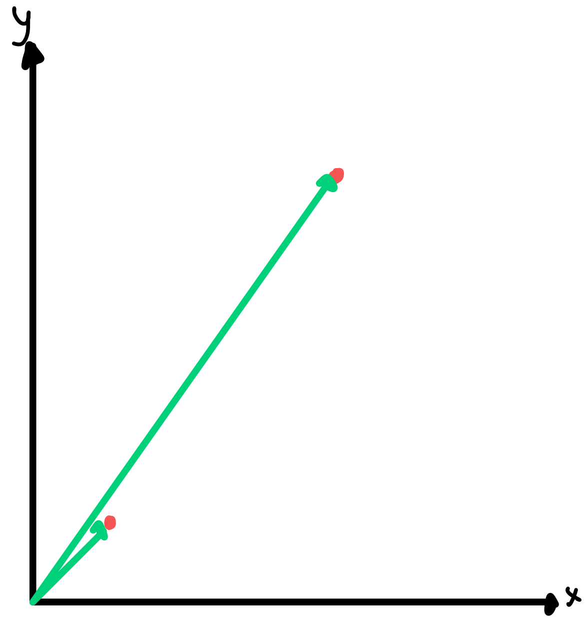

มุมน้อย ระยะห่างน้อย